04-01 다양한 의 법

여기서는 카운트 기반의 외에도 다양한 의 에는 어떤 것이 있으며, 앞으로 이 책에서는 어떤 순서로 을 학습하게 될 것인지에 대해서 먼저 설명합니다.

1. 의 법

의 은 크게 (Local Representation) 과 (Distributed Representation) 으로 나뉩니다. 은 해당 그 자체만 보고, 특정값을 하여 를 하는 이며, 은 그 를 하고자 을 참고하여 를 하는 입니다.

예를 들어 (강아지), (귀여운), (사랑스러운) 라는 가 있을 때 각 에 1 번, 2 번, 3 번 등과 같은 숫자를 (mapping) 하여 부여한다면 이는 에 해당됩니다. 반면, 표현 의 예를 하나 들어보면 해당 를 하기 위해 를 참고합니다. (강아지) 라는 근처에는 주로 (귀여운), (사랑스러운) 이라는 가 자주 등장하므로, 라는 어는 , 한 느낌이다로 를 정의합니다. 이렇게 되면 이 두 의 차이는 은 단어의 , 를 할 수 없지만, 은 의 를 할 수 있게 됩니다.

또한 비슷한 로 (Local Representation) 을 (Discrete Representation) 이라고도 하며, (Distributed Representation) 을 (Continuous Represnetation) 이라고도 합니다.

추가 의견으로 구글의 연구원 토마스 미코로브 (Tomas Mikolov) 는 2016 년에 한 발표에서 분석 (LSA) 이나 (LDA) 과 같은 들은 의 를 할 수 있다는 점에서 표현 (Continuous Represnetation) 이지만, 엄밀히 말해서 다른 접근의 론을 사용하고 있는 워드투벡터 ( ) 와 같은 (Distributed Representation) 은 아닌 것으로 분류하여 을 분산 을 포괄하고 있는 더 큰 개념으로 설명하기도 했습니다.

2. [redacted]의 카테고리화

이 책에서는 아래와 같은 기준으로 [redacted]을 카테고리화하여 작성되었습니다.

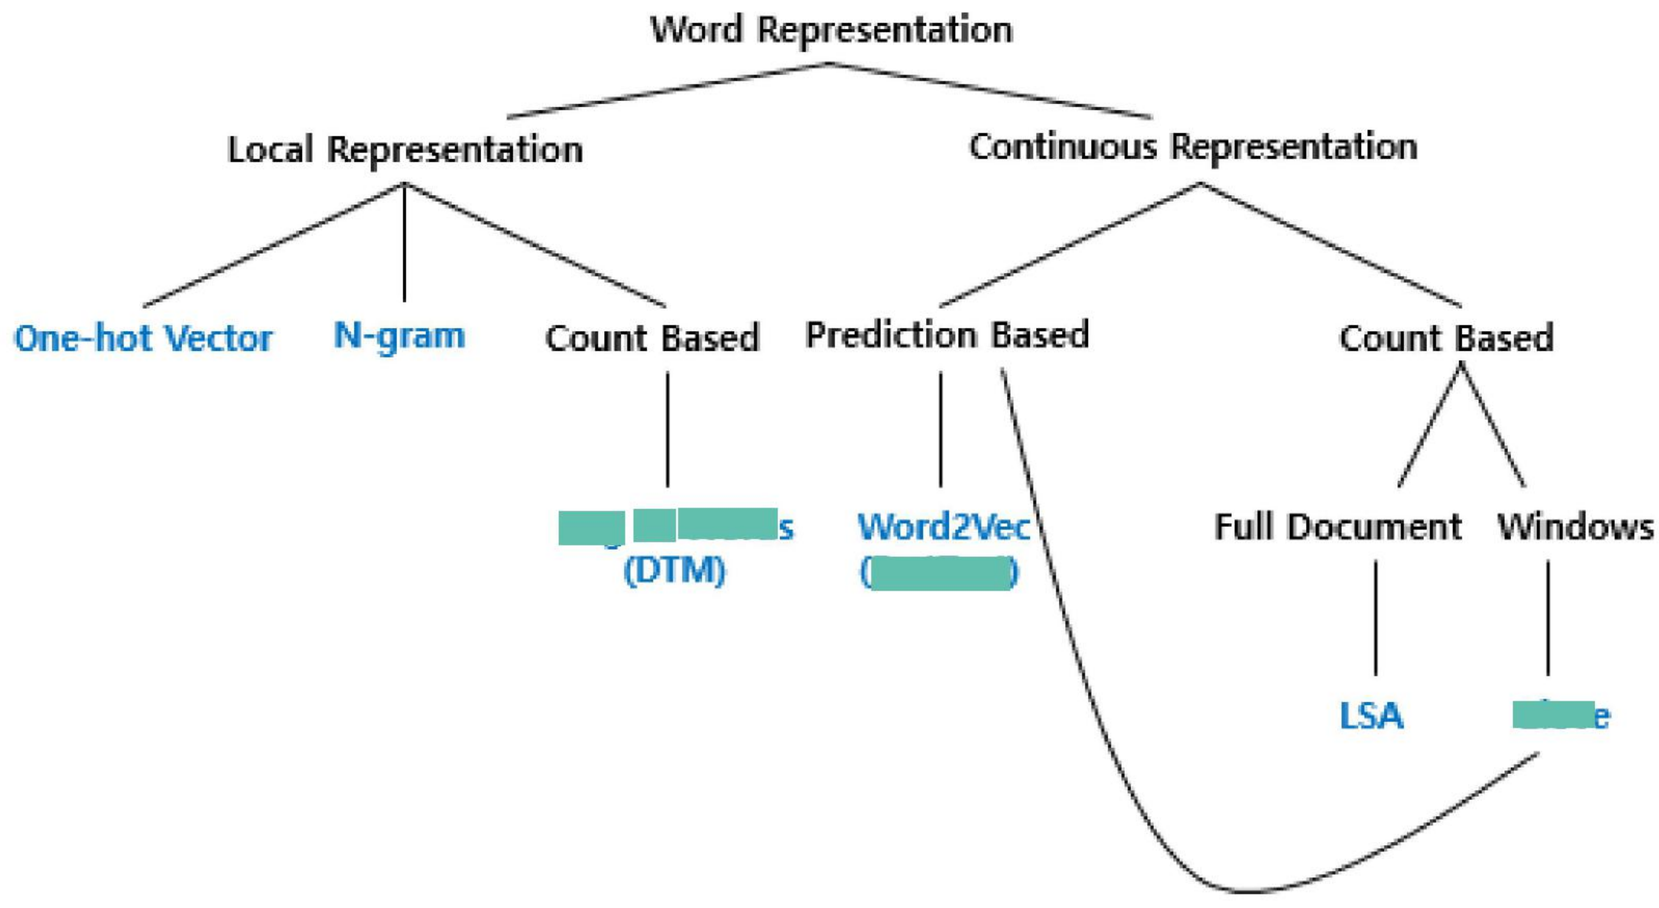

이번 챕터의 [redacted] 는 [redacted]에 (Local Representation) 에 속하며, [redacted]의 빈도수를 카운트 (Count) 하여 [redacted]를 수치화하는 [redacted] 입니다. 이 챕터에서는 BoW 와 그의 확장인 DTM(또는 TDM) 에 대해서 학습하고, 이러한 빈도수 기반 [redacted]에 [redacted]의 중요도에 따른 가중치를 줄 수 있는 [redacted] 에 대해서 학습합니다.

워드 임베딩 챕터에서는 [redacted] (Continuous Representation) 에 속하면서, 예측 (prediction) 을 기반으로 [redacted]의 [redacted]를 [redacted]하는 워드투벡터 (Word2Vec) 와 그의 확장인 패스트텍스트 ([redacted]) 를 학습하고, 예측과 카운트라는 두 가지 [redacted]이 모두 사용된 글로브 ([redacted]) 에 대해서 학습합니다.

이 책은 정윤성 (yyjsjsjs243@gmail.com) 님이 구매하신 전자책입니다.