04-01 다양한 [redacted]법

여기서는 카운트 기반의 단어 표현 방법 외에도 다양한 [redacted]에는 어떤 것이 있으며, 앞으로 이 책에서는 어떤 순서로 단어 표현 방법을 학습하게 될 것인지에 대해서 먼저 설명합니다.

1. [redacted]법

[redacted]은 크게 [redacted] ([redacted]) 방법과 [redacted] (Distributed Representation) 방법으로 나뉩니다. [redacted] 방법은 해당 단어 그 자체만 보고, 특정값을 [redacted]하여 단어를 표현하는 방법이며, [redacted] 방법은 그 단어를 표현하고자 주변을 참고하여 단어를 표현하는 방법입니다.

예를 들어 [redacted](강아지), [redacted](귀여운), [redacted](사랑스러운) 라는 단어가 있을 때 각 단어에 1 번, 2 번, 3 번 등과 같은 숫자를 [redacted] ([redacted]) 하여 부여한다면 이는 [redacted] 방법에 해당됩니다. 반면, 분산 표현 방법의 예를 하나 들어보면 해당 단어를 표현하기 위해 주변 단어를 참고합니다. [redacted](강아지) 라는 단어 근처에는 주로 [redacted](귀여운), [redacted](사랑스러운) 이라는 단어가 자주 등장하므로, [redacted] 라는 단어는 [redacted], [redacted] 한 느낌이다로 단어를 정의합니다. 이렇게 되면 이 두 방법의 차이는 [redacted] 방법은 단어의 의미, 뉘앙스를 표현할 수 없지만, [redacted] 방법은 단어의 뉘앙스를 표현할 수 있게 됩니다.

또한 [redacted]로 [redacted] 방법 ([redacted]) 을 [redacted] ([redacted]) 이라고도 하며, [redacted] ([redacted]) 을 [redacted] (Continuous Represnetation) 이라고도 합니다.

추가 의견으로 구글의 연구원 토마스 미코로브 (Tomas Mikolov) 는 2016 년에 한 발표에서 잠재 의미 분석 ([redacted]) 이나 [redacted] ([redacted]) 과 같은 방법들은 단어의 의미를 표현할 수 있다는 점에서 연속 표현 (Continuous Represnetation) 이지만, 엄밀히 말해서 다른 접근의 방법론을 사용하고 있는 워드투벡터 ([redacted]) 와 같은 [redacted] ([redacted]) 은 아닌 것으로 분류하여 [redacted]을 분산 표현을 포괄하고 있는 더 큰 개념으로 설명하기도 했습니다.

2. 단어 표현의 카테고리화

이 책에서는 아래와 같은 기준으로 단어 표현을 카테고리화하여 작성되었습니다.

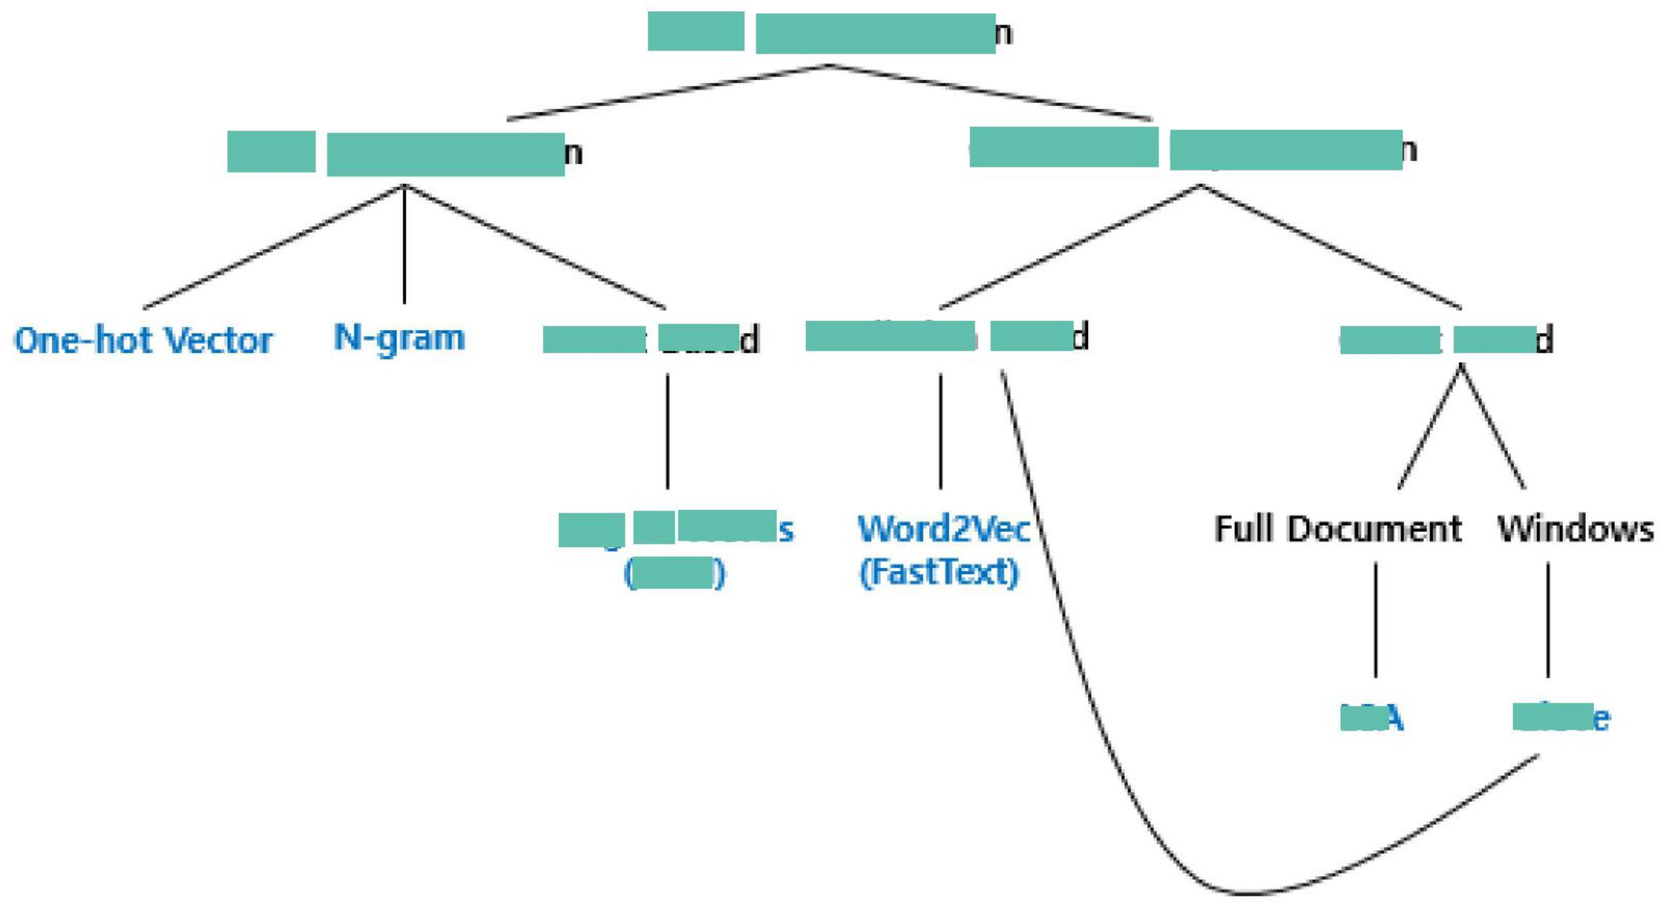

이번 챕터의 [redacted] 는 [redacted] 에 ([redacted]) 에 속하며, 단어의 빈도수를 카운트 (Count) 하여 단어를 수치화하는 단어 표현 방법입니다. 이 챕터에서는 BoW 와 그의 확장인 [redacted](또는 TDM) 에 대해서 학습하고, 이러한 빈도수 기반 단어 표현에 단어의 중요도에 따른 가중치를 줄 수 있는 [redacted] 에 대해서 학습합니다.

워드 임베딩 챕터에서는 [redacted] ([redacted]) 에 속하면서, 예측 (prediction) 을 기반으로 단어의 뉘앙스를 표현하는 [redacted] (Word2Vec) 와 그의 확장인 패스트텍스트 (FastText) 를 학습하고, 예측과 카운트라는 두 가지 방법이 모두 사용된 [redacted] ([redacted]) 에 대해서 학습합니다.

이 책은 정윤성 (yyjsjsjs243@gmail.com) 님이 구매하신 전자책입니다.