04-01 다양한 단어의 [redacted] 방법

여기서는 카운트 기반의 단어 표현 방법 외에도 다양한 단어의 표현 방법에는 어떤 것이 있으며, 앞으로 이 책에서는 어떤 순서로 단어 표현 방법을 학습하게 될 것인지에 대해서 먼저 설명합니다.

1. 단어의 표현 방법

단어의 표현 방법은 크게 국소 표현 (Local Representation) 방법과 분산 표현 (Distributed Representation) 방법으로 나뉩니다. 국소 표현 방법은 해당 단어 그 자체만 보고, 특정값을 맵핑하여 단어를 표현하는 방법이며, 분산 표현 방법은 그 단어를 표현하고자 주변을 참고하여 단어를 표현하는 방법입니다.

예를 들어 puppy(강아지), cute(귀여운), lovely(사랑스러운) 라는 단어가 있을 때 각 단어에 1 번, 2 번, 3 번 등과 같은 숫자를 맵핑 (mapping) 하여 부여한다면 이는 국소 표현 방법에 해당됩니다. 반면, 분산 표현 방법의 예를 하나 들어보면 해당 단어를 표현하기 위해 주변 단어를 참고합니다. puppy(강아지) 라는 단어 근처에는 주로 cute(귀여운), lovely(사랑스러운) 이라는 단어가 자주 등장하므로, puppy 라는 단어는 cute, lovely 한 느낌이다로 단어를 정의합니다. 이렇게 되면 이 두 방법의 차이는 국소 표현 방법은 단어의 의미, 뉘앙스를 표현할 수 없지만, 분산 표현 방법은 단어의 뉘앙스를 표현할 수 있게 됩니다.

또한 비슷한 의미로 국소 표현 방법 (Local Representation) 을 이산 표현 (Discrete Representation) 이라고도 하며, 분산 표현 (Distributed Representation) 을 연속 표현 (Continuous Represnetation) 이라고도 합니다.

추가 의견으로 구글의 연구원 토마스 미코로브 (Tomas Mikolov) 는 2016 년에 한 발표에서 잠재 의미 분석 (LSA) 이나 잠재 디리클레 할당 (LDA) 과 같은 방법들은 단어의 의미를 표현할 수 있다는 점에서 연속 표현 (Continuous Represnetation) 이지만, 엄밀히 말해서 다른 접근의 방법론을 사용하고 있는 워드투벡터 (Word2vec) 와 같은 분산 표현 (Distributed Representation) 은 아닌 것으로 분류하여 연속 표현을 분산 표현을 포괄하고 있는 더 큰 개념으로 설명하기도 했습니다.

2. 단어 표현의 카테고리화

이 책에서는 아래와 같은 기준으로 단어 표현을 카테고리화하여 작성되었습니다.

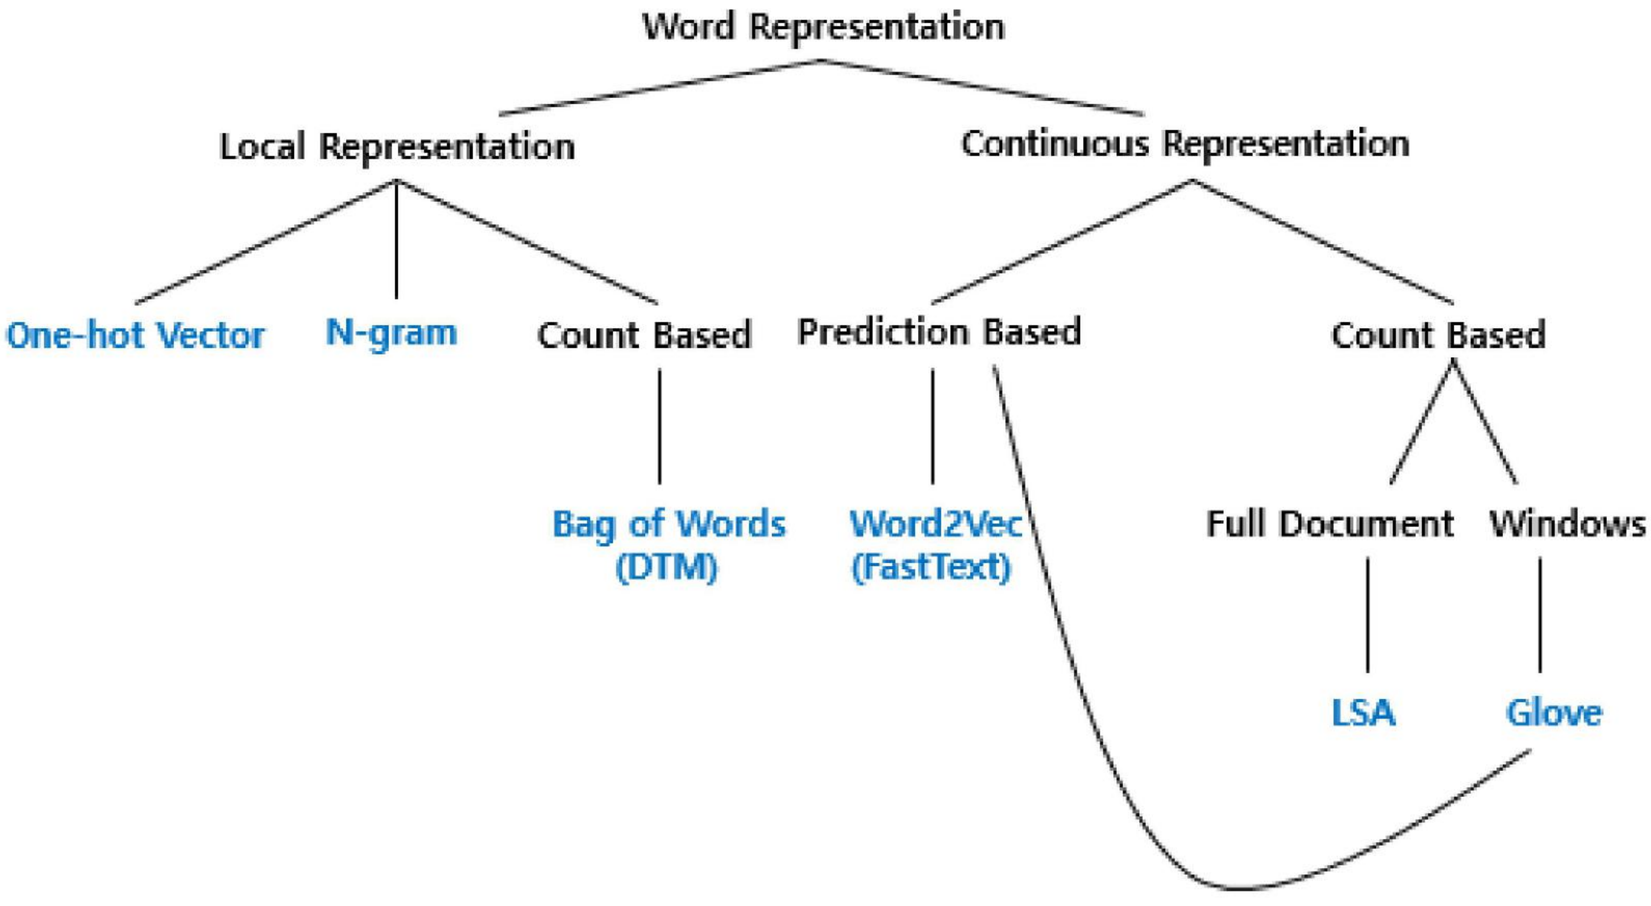

이번 챕터의 Bag of Words 는 국소 표현에 (Local Representation) 에 속하며, 단어의 빈도수를 카운트 (Count) 하여 단어를 수치화하는 단어 표현 방법입니다. 이 챕터에서는 BoW 와 그의 확장인 DTM(또는 TDM) 에 대해서 학습하고, 이러한 빈도수 기반 단어 표현에 단어의 중요도에 따른 가중치를 줄 수 있는 TF-IDF 에 대해서 학습합니다.

워드 임베딩 챕터에서는 연속 표현 (Continuous Representation) 에 속하면서, 예측 (prediction) 을 기반으로 단어의 뉘앙스를 표현하는 워드투벡터 (Word2Vec) 와 그의 확장인 패스트텍스트 (FastText) 를 학습하고, 예측과 카운트라는 두 가지 방법이 모두 사용된 글로브 (GloVe) 에 대해서 학습합니다.

이 책은 정윤성 (yyjsjsjs243@gmail.com) 님이 구매하신 전자책입니다.